ONNX CPU 推論結果比較報告

本地 AMD 與 Intel 新機比較 含新增樹數研究
COMP4330 P01 Group 2 整理日期 2026 年 11 月 4 日

主要結論 兩套 Windows CPU 環境均顯示 ONNX Runtime 比 scikit-learn 的機率推論 API 快，且保持各模型已測的分類決策。原始六次 100-tree 實驗關閉 ZipMap 均較快；新增研究則有一次反例，最佳批次與收益依模型和環境改變。

六次唯一實驗與角色

紀錄	日期	環境	用途
RUN-001	10 月 14 日	AMD 本地	原始正式實驗
RUN-002	10 月 30 日	AMD 本地	流程驗證，獨立列示
RUN-003	11 月 3 日	Intel MC235E10	首次獨立重現
RUN-004 至 006	11 月 3 日	同一 Intel 電腦	三次受控重測，用於同機穩定性

新結果包已包含本地 RUN-001、002 的副本。原始跨機比較為 **6 次唯一執行、72 組配置、72,000 筆計時**。另有 11 月 4 日樹數研究 9 次、108,000 筆，獨立列於補充章；合計 15 次、180 組配置、180,000 筆正式計時。

最直接的效能證據

Batch	本地 Tensor 加速	新機 Tensor 加速範圍	新機關閉 ZipMap 延遲降低
1	482.93 倍	393.40 至 402.05 倍	15.58 至 16.67%
16	157.48 倍	133.04 至 134.94 倍	16.95 至 17.57%
64	42.41 倍	24.34 至 24.79 倍	9.78 至 10.69%
256	9.95 倍	6.95 至 6.98 倍	9.69 至 10.26%

正確性 原始六次準確率均為 109/114，即 95.614%，ONNX 標籤一致率均為 100%。新增研究的 10-tree 準確率為 107/114，即 93.860%；100/500-tree 均為 109/114。全部 ONNX 誤差均低於容差 10^{-5}。

解讀範圍 效能數字限於暖機後、程序內、固定輸入的 API 計時，包含輸出物件建立，排除載入、session 建立、輸入準備及結果銷毀。這些倍數不能直接視為完整服務加速。

來源與口徑：[S01 至 S06] 每組 1,000 次計時；新機範圍為 RUN-004 至 006 各自統計值的最小值至最大值，不是信賴區間。

實驗設計與環境

設定	已確認的實際做法
資料與模型	Breast Cancer Wisconsin Diagnostic；569 筆、30 特徵、2 類；100 棵樹 RandomForestClassifier。
訓練測試切分	seed 42、分層 80/20；455 訓練、114 測試；索引互不重疊，資料先轉 contiguous float32。
批次	1、16、64、256；測試序列以 seed 42 打亂一次，後續呼叫重用固定批次；超過 114 以 resize 重複。
暖機與測量	每個 backend × batch 各 50 次暖機；10 輪 × 100 次測量；每輪按確定次序輪轉 backend。
執行限制	RF n_jobs=1；native threadpool=1；ORT intra/inter-op=1、sequential、CPUExecutionProvider、圖最佳化全開。
計時	perf_counter_ns 包住 probability API；準備 input/feed 與銷毀回傳物件在計時外。沒有停用或控制 GC 的紀錄。

環境差異

項目	本地 AMD	新機 Intel
CPU	Ryzen AI 7 H 350	Core i7-12700
實體核心 / 邏輯處理器	8 / 16	12 / 20
作業系統	Windows 11，build 26200	Windows 10，build 19044
Python	3.12.10	3.12.2
主要套件	兩邊相同：sklearn 1.9.1、ORT 1.31.0、skl2onnx 1.20.0、NumPy 2.5.4	版本相同，native library 選擇的架構不同
電源與負載	原始實驗未記錄；未由程式強制控制	人工記錄插電、Best performance、idle

計算口徑

Latency 採每次 API 呼叫時間的中位數。Throughput = batch size × 1,000 / median(ms)。Speedup = 同一次執行、同 batch 的 sklearn median / ONNX median。P25 至 P75 描述中央 50% 的觀測分布；P95 描述尾端延遲，兩者均不代表跨機器信賴區間。

Proposal 原規劃使用 CPU-only cloud VM；實際證據是在兩部 Windows 實體 CPU 電腦取得。核心比較設計維持一致，但執行平台的調整必須在正式報告交代。

來源與口徑：[S01 至 S06] config、dataset、runtime_settings、environment；[S08] data_model.py、benchmark.py、runtime.py；[S10] proposal 第 4 頁。

原始六次預測正確性與模型證據

轉換保留了本次測試的分類決策。全部六次執行、三種 backend 的 accuracy 均為 95.614%。ONNX 標籤與 sklearn 完全相同，但模型仍有 5 個測試案例分類錯誤；100% label agreement 不能寫成 100% accuracy。

Backend	Accuracy	對 sklearn 標籤一致率	最大機率絕對誤差
scikit-learn	109/114 = 95.614%	100%（基準）	0
ORT ZipMap on	109/114 = 95.614%	100%	6.55651×10^{-7}
ORT ZipMap off	109/114 = 95.614%	100%	6.55651×10^{-7}

保存的正確性結果均通過 shape、類別順序、機率有限性、機率範圍、每列機率和、標籤一致性及誤差容差檢查。原始 114 例與全部效能批次均有檢查；accuracy 只以原始測試集計算。

資料檔的直接檢查

資料部分	惡性	良性	總數
全資料	212	357	569
訓練集	170	285	455
測試集	42	72	114

實際 NPZ 索引顯示 train/test 交集為 0，聯集為 569；數值全部有限。Batch 256 仍只有 114 個唯一測試案例，其中 28 例各出現 3 次、86 例各出現 2 次。重測和合成批次沒有增加獨立準確率樣本。

相同模型的額外證據

六次唯一實驗的 dataset.npz、random_forest.joblib、batch_indices.npz 的實際 SHA256 各自一致。森林檔讀取確認 100 棵樹、30 features、classes [0,1]、random_state=42、n_jobs=1。每棵樹的深度範圍為 4 至 10。

12 個 ONNX 檔案均通過本次靜態 onnx.checker 檢查。原始檔案 hash 的不同僅來自隨機 graph.name；在記憶體移除該名稱後，同一輸出表示跨六次執行的 protobuf 完全一致。這支持圖與權重一致，並非模型改動。

表示	主要圖節點	序列化檔案大小
ZipMap on	TreeEnsembleClassifier + Cast + ZipMap	130,821 bytes
ZipMap off	TreeEnsembleClassifier	130,671 bytes
sklearn forest	joblib serialization	324,329 bytes

來源與口徑：[S01 至 S07] correctness、dataset、NPZ、model、conversion 與工作表。預測 PASS 為保存的既有驗證證據；本輪沒有重新執行模型推論或訓練。檔案大小只代表本模型的序列化大小。

推論延遲與相對加速

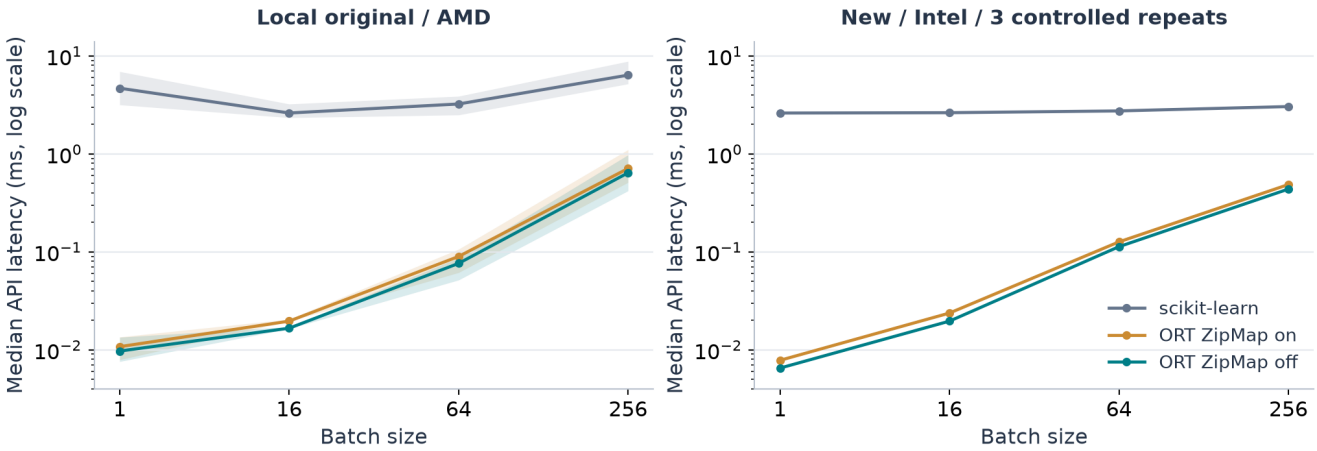


圖 1 每次 API 呼叫的 median latency，以對數軸呈現。左圖陰影為本地 P25 至 P75；右圖陰影為三次新機重測的 median 最小值至最大值。兩者描述不同層次的變動。

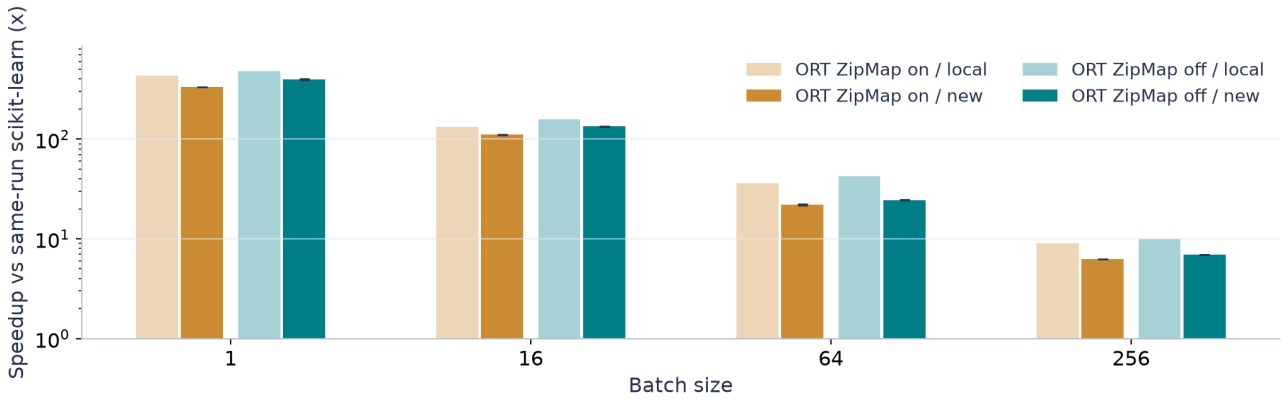


圖 2 相對同一次 sklearn 基準的加速。新機柱高為三次加速倍數的中位數，誤差線為三次倍數的最小值至最大值。

Batch	本地 Tensor ms	新機 Tensor ms 範圍	新機相對本地延遲
1	0.0097	0.00650 至 0.00660	降低 31.96 至 32.99%
16	0.0166	0.01960 至 0.01970	增加 18.07 至 18.67%
64	0.0762	0.11070 至 0.11395	增加 45.28 至 49.54%
256	0.64045	0.43570 至 0.44090	降低 31.16 至 31.97%

新機在 batch 1、256 的 Tensor 延遲較低，在 batch 16、64 則較高。跨機差異同時涉及 CPU、OS、Python patch version 和未控制負載，不能當成純 CPU 或程式改版的因果效果。

加速倍數會受 sklearn 基準影響。例如 batch 1：新機 ONNX 從本地 0.00970 ms 降至 0.00650 至 0.00660 ms；但 sklearn 也由 4.6844 ms 降至 2.5571 至 2.6192 ms，所以相對倍數由 482.93 變為 393.40 至 402.05。

來源與口徑：[S01、S04 至 S06]；完整 72 組配置列於附錄。

批次吞吐量與 ZipMap 設定

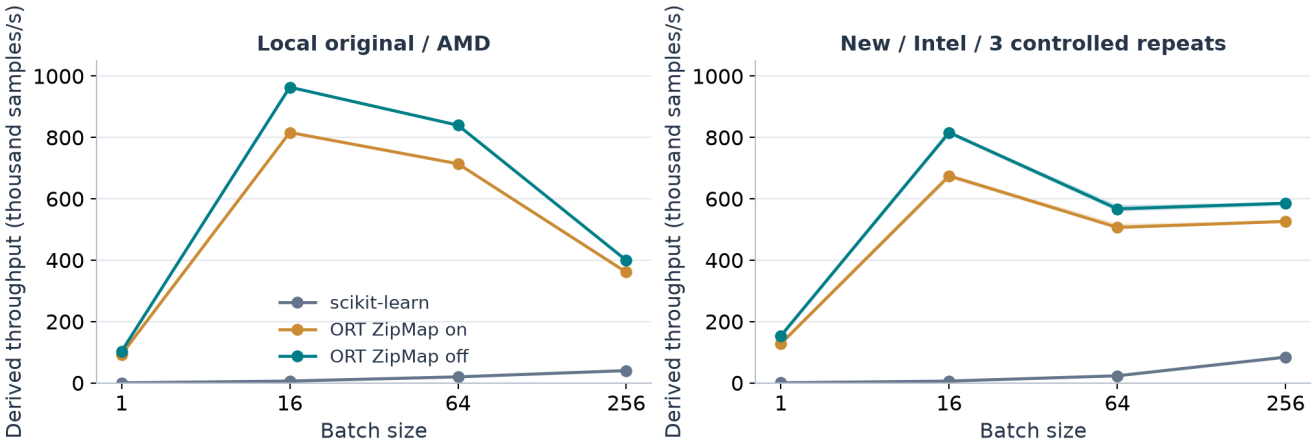


圖 3 由 batch / median latency 推算的吞吐量。新機線條為三次各自吞吐量的中位數；陰影為最小值至最大值。這不是端到端服務壓力測試。

本地原始實驗的 Tensor 最高吞吐量出現在 batch 16，約 963,855 筆/秒；新機三次重測同樣以 batch 16 最高，約 812,183 至 816,327 筆/秒。新機 batch 256 僅約 580,631 至 587,560 筆/秒。

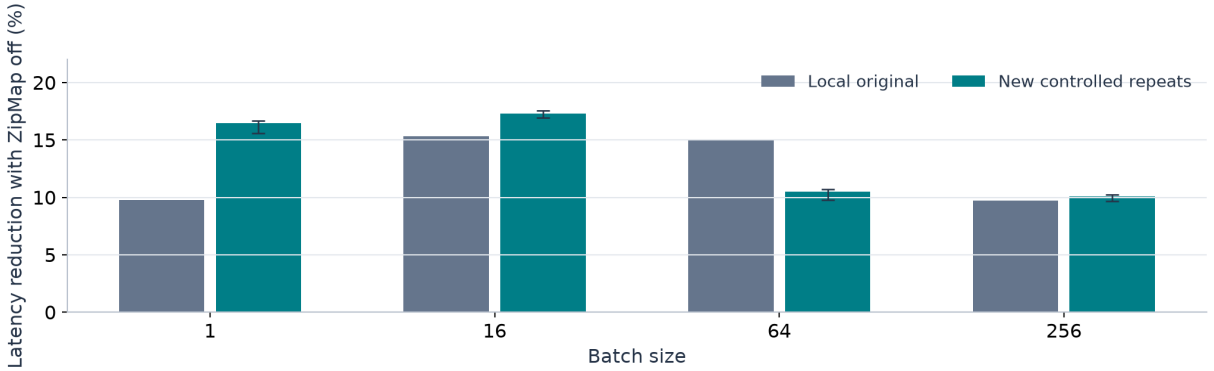


圖 4 關閉 ZipMap 的延遲降低率 = 100 × (1 - Tensor median / ZipMap median)。新機柱高為三次降低率的中位數，誤差線為範圍。

Batch	本地降低率	新機降低率範圍
1	9.77%	15.58 至 16.67%
16	15.31%	16.95 至 17.57%
64	14.96%	9.78 至 10.69%
256	9.70%	9.69 至 10.26%

若應用可直接消費機率矩陣，ZipMap off 是有量測支持的設定。原始六次比較的是完整圖、API 與輸出表示的組合差異，包含 Cast 和 opset imports 的差異。補充章另有 profiler 證據，但仍不能把全部改善分離歸因於單一 operator。

批次選擇仍須實測。本地 RUN-002 流程驗證的 Tensor 最佳批次是 64，顯示 batch 16 的最佳觀察不能當成跨執行或跨環境的固定規律。

來源與口徑：[S01、S02、S04 至 S06]；固定重複輸入的暖機 API 吞吐量。

新機三次重測的穩定性

只有 RUN-004 至 006 是本次指定的同機受控重測。RUN-003 為首次獨立重現；RUN-001、002 屬本地歷史資料，不混入三次穩定性統計。成功日誌記錄各次執行間隔 60 秒。

每次執行的 Tensor median 與相對加速

Batch	RUN-004 ms	RUN-005 ms	RUN-006 ms	加速倍數範圍
1	0.0065	0.0066	0.0065	393.40 至 402.05
16	0.0196	0.0196	0.0197	133.04 至 134.94
64	0.1128	0.1107	0.11395	24.34 至 24.79
256	0.4371	0.4357	0.4409	6.95 至 6.98

觀測分布與尾端延遲

Batch	本地 Tensor IQR / median	新機 Tensor IQR / median	新機 Tensor P95 ms 範圍
1	60.05%	3.08 至 4.62%	0.00690 至 0.00720
16	4.82%	4.57 至 4.59%	0.02130 至 0.02280
64	45.93%	4.72 至 5.70%	0.11730 至 0.12311
256	86.81%	1.65 至 2.02%	0.44780 至 0.46670

三次 Tensor median 的變動範圍小，支持這部電腦在短時間內的重複性。新機大部分配置的中央分布也較本地原始實驗集中；但本地只有一筆原始實驗和一次流程驗證，沒有對稱的三次受控重測，不能據此建立兩機穩定性的普遍排名。

尾端延遲仍需保留。RUN-006、batch 1 的 ZipMap on median 為 0.0078 ms，但 P95 為 0.022205 ms；前兩次同配置 P95 約 0.0083 至 0.0085 ms。這說明 median 穩定不代表所有尾端觀測都穩定。

可以與不可以支持的推論

目前可支持：相同模型與設定在第二部電腦上保持預測一致性，ORT 在全部測試批次較 sklearn 快，ZipMap off 在各次都較快。三次重測支持同機、短期的重複性。

目前無法支持：跨所有 CPU 或模型的固定加速倍數、統計上顯著的跨機器優劣、實際請求到達與併發負載下的 SLA，或對新資料族群的準確率保證。CPU affinity、頻率、溫度和 GC 均未被程式固定。

來源與口徑：[S04 至 S06] summary / timings / run_conditions；[S09] team 成功日誌。IQR = P75 - P25，不是信賴區間。

載入轉換成本與執行紀錄

Setup 時間獨立於主要 warm inference 比率。各 setup_times.json 只記錄一次觀察（repetitions=1）；下表的新機範圍是三次執行各自一次的觀察，不能視為冷啟動分布。

步驟	本地一次觀察 ms	新機三次平均 ms	新機觀察範圍 ms
模型訓練	121.329	79.533	79.109 至 80.175
載入 sklearn	24.243	7.730	7.632 至 7.912
轉換 ZipMap on	89.933	85.713	85.347 至 86.002
轉換 Tensor	71.980	74.434	73.870 至 74.798
建立 ZipMap session	6.584	4.713	4.621 至 4.854
建立 Tensor session	2.022	1.866	1.783 至 1.922

訓練與轉換通常發生在模型準備階段，載入與 session 建立則依部署生命週期而定。這些步驟不應直接相加，當成每個請求都會發生的成本。完整服務效能仍需另行量測。

失敗與恢復

11 月 3 日 19:36:01 的首次啟動將 --plugged-in 設為小寫 yes，CLI 僅接受 Yes、No、Not recorded，因此在量測前停止。它屬真實的流程啟動失敗，未產生有效量測，不列入效能統計。19:37:24 重開後，RUN-003 至 006 的 benchmark、verification 與 Excel 匯入均成功。

Setup 日誌顯示 pinned packages 安裝完成，pip check 回報 No broken requirements found。pip 更新 notice 屬資訊。10 月 30 日的重複匯入檢查回報 imported=false，代表沿用 RUN-002，而非新實驗或量測失敗。

歷史驗證的時間界線

日期	保存的證據	本次解讀
10 月 14 日	8 個測試、16 個 source files 型別檢查；當時尚無 teammate rerun	當日快照，沒有本輪重新執行
10 月 30 日	25 個測試、21 個 source files 型別檢查；當時尚無第二部實體電腦	流程驗證快照
11 月 3 日	第二部電腦四次完整實驗及既有 verification PASS	補充跨機重現與三次受控重測證據

來源與口徑：[S01、S04 至 S06] setup_times；[S09] setup、team、workflow、automation_validation_summary；時間為香港本地日誌時間，run ID 使用 UTC。

檔案完整性與報告建議

本輪已完成的證據核對

項目	結果
原始計時	六次唯一實驗 72,000 筆；median、P25、P75、P95、throughput、speedup 全部重算吻合
結果包 manifest	168 個項目逐檔 hash 核對通過，沒有缺檔或 mismatch
Provenance	六次共 30 個 artifact hash 通過；閱讀時的 12 個原始模組符合歷史 source hashes；新增研究使用另一來源快照
模型結構	12 個唯一 ONNX 靜態檢查通過；NPZ 與森林檔結構及一致性已檢查
工作簿	三份共 12 張工作表全部閱讀；效能、正確性、設定與 CSV/JSON 對帳一致
圖片與文檔	18 張唯一結果圖已檢視；方法說明、程式模組、proposal 與課程附件已閱讀

追蹤表的限制及過時內容

new 的兩份工作簿完全相同，均有 1,040 個公式而沒有保存計算快取；檔案設定要求 Excel 開啟重算。本 PDF 直接採原始值與獨立計算。相較之下，本地工作簿有 322 個非空快取，已填資料的計算值皆吻合；其他空槽位不當作錯誤。

Guide 仍保存歷史 AMD 的 8/16 核心與 Windows 11 說明，不能套用到 Intel 的 12/20 和 Windows 10。Run Log 的『RUN-002 至 020 空白』也已過時。各次環境應以自己的 environment.json 為準；舊報告草稿中『尚未 teammate rerun』是歷史狀態。

結論與有證據支持的改善

部署設定：在需要機率矩陣的應用中優先測試 Tensor / ZipMap off；兩套環境均量得延遲改善。若下游需要 dictionary，還需把實際資料轉換成本納入端到端比較。

批次選擇：按目標工作負載量測 batch，而不預設越大越好。原始實驗及新機重測以 16 的 Tensor 吞吐量最佳，本地流程驗證以 64 最佳；新增樹數研究的最佳批次亦依模型改變，詳見補充章。

下一步驗證：若要比較硬體，補上兩機對稱的三次受控重測，統一 OS、Python、電源與背景條件並記錄頻率/溫度。若要宣稱服務加速，另量冷啟動、變動輸入、併發、前後處理及 P95/P99。這些屬後續建議，本輪未新增執行。

可用於正式結果章的表述：本實驗在兩套單執行緒 CPU 環境觀察到 ORT 機率 API 的大幅加速，並保持 114 個測試案例的分類決策。改善幅度依批次與環境改變；Tensor 輸出提供額外延遲收益，但結果不代表完整服務成本或普遍硬體效能。

來源與口徑：[S07 至 S10]；本輪沒有更改原始來源、重新訓練、執行新 benchmark，或重新執行保存紀錄中的測試套件。

附錄 完整配置結果1

全部值由已保存的逐次計時重新核對。每一列均為 1,000 次 API 呼叫；ms 為每次批次呼叫時間，k/s 代表千筆樣本每秒。Speedup 的分母是同 run、同 batch 的比較 backend 延遲。

RUN-001 本地原始實驗

Backend	批次	Median ms	P25 - P75 ms	P95 ms	千筆/秒	倍數
sklearn	1	4.6844	3.17157 - 6.9207	12.19507	0.213	1.00
ZipMap on	1	0.01075	0.0079 - 0.0135	0.04113	93.023	435.76
ZipMap off	1	0.0097	0.00758 - 0.0134	0.03623	103.093	482.93
sklearn	16	2.61425	2.34353 - 3.22697	4.10991	6.120	1.00
ZipMap on	16	0.0196	0.0195 - 0.0205	0.0397	816.327	133.38
ZipMap off	16	0.0166	0.0164 - 0.0172	0.0276	963.855	157.48
sklearn	64	3.232	2.49927 - 3.87648	5.21484	19.802	1.00
ZipMap on	64	0.0896	0.0614 - 0.10622	0.17732	714.286	36.07
ZipMap off	64	0.0762	0.0515 - 0.0865	0.10982	839.895	42.41
sklearn	256	6.37035	5.18602 - 8.8037	11.54086	40.186	1.00
ZipMap on	256	0.70925	0.51153 - 1.1034	1.59343	360.945	8.98
ZipMap off	256	0.64045	0.4192 - 0.97515	1.39473	399.719	9.95

RUN-002 本地流程驗證

Backend	批次	Median ms	P25 - P75 ms	P95 ms	千筆/秒	倍數
sklearn	1	4.6051	3.59855 - 5.16483	7.2959	0.217	1.00
ZipMap on	1	0.01305	0.0111 - 0.0158	0.02021	76.628	352.88
ZipMap off	1	0.0128	0.0097 - 0.0137	0.0155	78.125	359.77
sklearn	16	4.38445	3.36273 - 4.92373	7.45182	3.649	1.00
ZipMap on	16	0.0438	0.0403 - 0.0456	0.05634	365.297	100.10
ZipMap off	16	0.0352	0.0241 - 0.0374	0.04925	454.545	124.56
sklearn	64	4.76555	3.6477 - 5.38715	8.61608	13.430	1.00
ZipMap on	64	0.091	0.0873 - 0.14233	0.17464	703.297	52.37
ZipMap off	64	0.0778	0.0734 - 0.1205	0.23148	822.622	61.25
sklearn	256	5.16	4.06827 - 5.73835	6.93837	49.612	1.00
ZipMap on	256	0.6049	0.4679 - 0.674	0.90222	423.210	8.53
ZipMap off	256	0.48845	0.397 - 0.571	0.71652	524.107	10.56

RUN-002 是流程驗證，列出作透明比較，不納入新機三次受控重測。

來源與口徑：[S01、S02] 各自的 summary.csv 與 timings.csv。完整精度保留於原始檔，表內四捨五入。

附錄 完整配置結果2

全部值由已保存的逐次計時重新核對。每一列均為 1,000 次 API 呼叫；ms 為每次批次呼叫時間，k/s 代表千筆樣本每秒。Speedup 的分母是同 run、同 batch 的比較 backend 延遲。

RUN-003 新機獨立重現

Backend	批次	Median ms	P25 - P75 ms	P95 ms	千筆/秒	倍數
sklearn	1	2.56825	2.5503 - 2.59322	2.65225	0.389	1.00
ZipMap on	1	0.0077	0.0076 - 0.0079	0.0084	129.870	333.54
ZipMap off	1	0.0065	0.0064 - 0.0066	0.007	153.846	395.12
sklearn	16	2.6286	2.60878 - 2.6626	2.77011	6.087	1.00
ZipMap on	16	0.0239	0.0235 - 0.0253	0.0271	669.456	109.98
ZipMap off	16	0.0199	0.0195 - 0.0205	0.0221	804.020	132.09
sklearn	64	2.76105	2.7414 - 2.79698	2.88981	23.180	1.00
ZipMap on	64	0.1238	0.1216 - 0.12712	0.1314	516.963	22.30
ZipMap off	64	0.1113	0.109 - 0.1146	0.119	575.022	24.81
sklearn	256	3.0321	3.01607 - 3.06022	3.12231	84.430	1.00
ZipMap on	256	0.4857	0.4816 - 0.4908	0.4995	527.074	6.24
ZipMap off	256	0.4375	0.4335 - 0.44203	0.4489	585.143	6.93

RUN-003 是首次獨立重現；同機重測統計採 RUN-004 至 006。

RUN-004 新機受控重測一

Backend	批次	Median ms	P25 - P75 ms	P95 ms	千筆/秒	倍數
sklearn	1	2.5571	2.5402 - 2.58383	2.73554	0.391	1.00
ZipMap on	1	0.0077	0.0076 - 0.0079	0.0083	129.870	332.09
ZipMap off	1	0.0065	0.0064 - 0.0066	0.0069	153.846	393.40
sklearn	16	2.6075	2.5917 - 2.62893	2.70881	6.136	1.00
ZipMap on	16	0.0237	0.0233 - 0.0242	0.0271	675.105	110.02
ZipMap off	16	0.0196	0.0193 - 0.0202	0.0224	816.327	133.04
sklearn	64	2.7459	2.73128 - 2.77393	2.88048	23.307	1.00
ZipMap on	64	0.1263	0.123 - 0.1292	0.1355	506.730	21.74
ZipMap off	64	0.1128	0.1098 - 0.1157	0.121	567.376	24.34
sklearn	256	3.03575	3.0183 - 3.06155	3.13236	84.328	1.00
ZipMap on	256	0.4862	0.4822 - 0.4905	0.5096	526.532	6.24
ZipMap off	256	0.4371	0.4333 - 0.4417	0.4667	585.678	6.95

來源與口徑：[S03、S04] 各自的 summary.csv 與 timings.csv。完整精度保留於原始檔，表內四捨五入。

附錄 完整配置結果3

全部值由已保存的逐次計時重新核對。每一列均為 1,000 次 API 呼叫；ms 為每次批次呼叫時間，k/s 代表千筆樣本每秒。Speedup 的分母是同 run、同 batch 的比較 backend 延遲。

RUN-005 新機受控重測二

Backend	批次	Median ms	P25 - P75 ms	P95 ms	千筆/秒	倍數
sklearn	1	2.6192	2.60098 - 2.65135	2.76378	0.382	1.00
ZipMap on	1	0.0079	0.0078 - 0.0081	0.0085	126.582	331.54
ZipMap off	1	0.0066	0.0065 - 0.0068	0.0072	151.515	396.85
sklearn	16	2.63425	2.6054 - 2.66715	2.73965	6.074	1.00
ZipMap on	16	0.0236	0.0232 - 0.0241	0.02811	677.966	111.62
ZipMap off	16	0.0196	0.0192 - 0.0201	0.0213	816.327	134.40
sklearn	64	2.7439	2.7275 - 2.7727	2.92341	23.324	1.00
ZipMap on	64	0.1237	0.1215 - 0.12702	0.1309	517.381	22.18
ZipMap off	64	0.1107	0.10867 - 0.1139	0.1173	578.139	24.79
sklearn	256	3.04255	3.0251 - 3.07465	3.18262	84.140	1.00
ZipMap on	256	0.4855	0.4815 - 0.49123	0.50831	527.291	6.27
ZipMap off	256	0.4357	0.4326 - 0.4398	0.4478	587.560	6.98

RUN-006 新機受控重測三

Backend	批次	Median ms	P25 - P75 ms	P95 ms	千筆/秒	倍數
sklearn	1	2.61335	2.5872 - 2.6518	2.76387	0.383	1.00
ZipMap on	1	0.0078	0.0076 - 0.008	0.0222	128.205	335.04
ZipMap off	1	0.0065	0.0064 - 0.0067	0.007	153.846	402.05
sklearn	16	2.65825	2.6333 - 2.689	2.77633	6.019	1.00
ZipMap on	16	0.0239	0.0234 - 0.0251	0.0276	669.456	111.22
ZipMap off	16	0.0197	0.0194 - 0.0203	0.0228	812.183	134.94
sklearn	64	2.79545	2.76118 - 2.83003	2.94241	22.894	1.00
ZipMap on	64	0.1263	0.123 - 0.1297	0.13671	506.730	22.13
ZipMap off	64	0.11395	0.1106 - 0.1171	0.12311	561.650	24.53
sklearn	256	3.07875	3.046 - 3.12605	3.26306	83.151	1.00
ZipMap on	256	0.4882	0.4835 - 0.49452	0.50201	524.375	6.31
ZipMap off	256	0.4409	0.4368 - 0.4457	0.45391	580.631	6.98

來源與口徑：[S05、S06] 各自的 summary.csv 與 timings.csv。完整精度保留於原始檔，表內四捨五入。

補充研究 模型樹數與批次效能

11 月 4 日另完成一組本地 AMD 研究：10、100、500 棵樹各 3 次，共 9 個子實驗、108 組配置及 108,000 筆正式計時。每輪樹數順序依次為 10/100/500、100/500/10、500/10/100。它使用新的程式快照，與前述六次歷史結果分開分析。

樹數	測試準確率	ONNX 最大機率誤差	Tensor ONNX bytes
10	107/114 = 93.8596%	1.19209×10^{-7}	12,546
100	109/114 = 95.6140%	6.55651×10^{-7}	130,671
500	109/114 = 95.6140%	5.78165×10^{-6}	669,804

所有九次 ONNX 與各自 sklearn 森林的標籤一致率均為 100%，誤差低於 10^{-5}。100 棵相較 10 棵在此測試集多判對 2 例；增至 500 棵沒有再增加正確例數，卻增加模型大小與時間。因此 100 棵是本次固定 split 的合理折衷判斷，並非普遍最佳模型。

Tensor 相對加速的三次中位數

Batch	10 棵樹	100 棵樹	500 棵樹
1	54.50 倍	346.37 倍	1051.97 倍
16	46.21 倍	131.74 倍	153.72 倍
64	27.07 倍	55.09 倍	24.35 倍
256	13.76 倍	9.95 倍	6.96 倍

模型增大時，加速比在 batch 1/16 上升；batch 64 不單調，batch 256 反而下降。最大 1,051.97 倍是 500 棵、batch 1 的暖機 API 觀察，不能代表整個服務或所有工作負載。

吞吐量最高的已測批次

樹數	最佳 Tensor batch	三次吞吐量中位數（筆/秒）
10	256	5,458,422
100	64	752,056
500	16	114,449

這份彙總先在各次執行計算指標，再分別取三次中位數。加速比不能直接以表中的彙總 sklearn latency 除以彙總 ONNX latency 重建；P95 也不是合併 3,000 calls 後的 P95。範圍僅代表三次觀察的最小值至最大值。

來源與口徑：[S11] study_config、summary、runs、correctness、model_sizes。資料日期為香港 11 月 4 日；原始 recorded_at_utc 為 11 月 3 日 16:10 至 16:16。

補充研究 ZipMap 反例與執行路徑

ZipMap off 多數較快，但有明確反例。新增研究的 36 個同 run、同模型、同 batch 配對中，35 個關閉後較快、1 個較慢。repeat_1/trees_500、batch 1 的 on=0.01755 ms，off=0.02000 ms，關閉後增加 13.96%。

樹數	Batch 1 降低率	Batch 16	Batch 64	Batch 256
10	14.62%	26.46%	45.61%	60.93%
100	14.57%	14.67%	33.65%	15.20%
500	16.94%	5.16%	2.76%	2.96%

上表是各配對降低率的三次中位數。500 棵、batch 1 的三次範圍為 -13.96% 至 21.67%，顯示極小延遲配置對執行波動敏感。因此原始六次的『各次都較快』觀察只能限定該批 100-tree 資料。

Profiling 的量測範圍

全部正式計時完成後，才另行做 50 次暖機與 100 次 profiling calls。cProfile 將 exclusive self time 按來源函式分類；cumulative time 包含子呼叫，不能加總。ORT 另開 profiling session，將 Node kernel events 配到 model_run 時間窗並排除前 50 個暖機 run。

Batch 256 配置	ON 森林 kernel µs	ON ZipMap µs	OFF 森林 kernel µs
10 棵樹	41.01	38.70	46.84
100 棵樹	560.09	48.71	552.40
500 棵樹	3967.51	61.46	3848.17

表內為各次 operator mean 的三次中位數。大森林的計算成本增加，ZipMap 的相對重要性降低，與部分大模型設定的關閉收益較小相符。cProfile 也顯示 validation、dispatch、aggregation 等實際路徑，但無法把未追蹤的 native 工作精確分離。

證據界線：兩種 profiler 都有額外開銷且計時邊界不同；ORT kernel events 未涵蓋全部 Python binding、feed 處理及輸出容器物化。不能用正式 API latency 減 kernel time 估算精確 wrapper 成本，也不能把 profile 百分比解釋成正式加速倍數的因果占比。

新增結果的完整性

新增 348 檔均已讀取或依類型檢查；203 JSON、36 pstats、72 ORT raw traces 均可解析。頂層 285 個 artifact hashes 及子實驗 90 個 hashes 全部通過，九次原始 108,000 筆計時與彙總一致。31 張新增圖已目視檢查。

新研究保存的 16 個核心來源與其快照相符；原始 12 模組中的 cli、config、reporting、runtime 已改動，另新增四模組。這是新研究版本，不能宣稱現行程式仍逐檔等於舊來源。100-tree 的森林檔與舊六次相同；100-tree ONNX 只差 metadata 或 opset 條目排列，圖與權重保持一致。

來源與口徑：[S11] profiling_summary、36 pstats、72 ORT traces、各 run verification 及 provenance；本輪只閱讀和核對，未執行新研究、推論或 profiling。

補充附錄 10 棵樹完整彙總

以下每列代表三個子實驗，每個子實驗 1,000 次正式 API 呼叫。Median、P95、throughput、speedup 均先在各次計算後再取中位數；方括號內為三次觀察範圍。ms 為每次批次呼叫時間。

Backend	批次	Median ms [範圍]	P95 ms	千筆/秒	加速 [範圍]
sklearn	1	0.605 [0.581, 0.6134]	0.93984	1.653	1.00 [1.00, 1.00]
ZipMap on	1	0.013 [0.0098, 0.0161]	0.0152	76.923	46.54 [38.10, 59.29]
ZipMap off	1	0.0111 [0.0083, 0.0143]	0.0133	90.090	54.50 [42.90, 70.00]
sklearn	16	0.6142 [0.58905, 0.64225]	0.99494	26.050	1.00 [1.00, 1.00]
ZipMap on	16	0.0189 [0.015, 0.02]	0.0282	846.561	33.98 [30.71, 39.27]
ZipMap off	16	0.0139 [0.0108, 0.0152]	0.021	1151.079	46.21 [40.41, 54.54]
sklearn	64	0.60905 [0.6062, 0.6187]	0.90493	105.082	1.00 [1.00, 1.00]
ZipMap on	64	0.042 [0.0296, 0.0442]	0.05342	1523.810	14.50 [14.00, 20.48]
ZipMap off	64	0.0225 [0.0161, 0.0259]	0.02835	2844.444	27.07 [23.89, 37.65]
sklearn	256	0.66125 [0.64555, 0.73]	1.03002	387.146	1.00 [1.00, 1.00]
ZipMap on	256	0.1274 [0.0942, 0.14265]	0.15932	2009.419	5.12 [5.07, 7.02]
ZipMap off	256	0.0469 [0.0368, 0.06085]	0.07679	5458.422	13.76 [12.00, 17.97]

Setup 與模型規模

總節點 326，最大深度 10；joblib 31,369 bytes，Tensor ONNX 12,546 bytes。

Setup 步驟	中位數 ms	三次一次觀察的範圍 ms
訓練	10.823	8.488 至 12.620
載入 sklearn	8.018	5.348 至 8.031
Tensor 轉換	12.669	8.666 至 16.089
Tensor session 建立	0.740	0.708 至 0.931

Setup 各階段每個子實驗只觀察一次，且各階段排除部分保存 / 序列化工作；不能直接相加為完整 cold-start 或請求成本。

來源與口徑：[S11] summary.csv、runs.csv、model_sizes.csv、setup_times.csv；各子實驗 P25/P75 與更完整小數保留於其 summary / timings。

補充附錄 100 棵樹完整彙總

以下每列代表三個子實驗，每個子實驗 1,000 次正式 API 呼叫。Median、P95、throughput、speedup 均先在各次計算後再取中位數；方括號內為三次觀察範圍。ms 為每次批次呼叫時間。

Backend	批次	Median ms [範圍]	P95 ms	千筆/秒	加速 [範圍]
sklearn	1	4.46815 [4.46075, 4.53]	7.55619	0.224	1.00 [1.00, 1.00]
ZipMap on	1	0.0148 [0.0146, 0.0151]	0.0199	67.568	301.40 [295.90, 310.27]
ZipMap off	1	0.0129 [0.0099, 0.0129]	0.0207	77.519	346.37 [345.79, 457.58]
sklearn	16	4.5052 [4.33625, 4.59775]	6.78021	3.551	1.00 [1.00, 1.00]
ZipMap on	16	0.0406 [0.0405, 0.04125]	0.0489	394.089	109.22 [107.07, 113.25]
ZipMap off	16	0.0349 [0.032, 0.0352]	0.04875	458.453	131.74 [127.99, 135.51]
sklearn	64	4.7093 [4.6879, 4.7419]	6.57597	13.590	1.00 [1.00, 1.00]
ZipMap on	64	0.1327 [0.12825, 0.13545]	0.2639	482.291	35.73 [34.77, 36.55]
ZipMap off	64	0.0851 [0.0803, 0.1127]	0.16355	752.056	55.09 [41.79, 59.05]
sklearn	256	5.0602 [4.9908, 5.2026]	7.5787	50.591	1.00 [1.00, 1.00]
ZipMap on	256	0.59315 [0.5915, 0.61545]	1.03719	431.594	8.45 [8.44, 8.53]
ZipMap off	256	0.5016 [0.4792, 0.52535]	0.65449	510.367	9.95 [9.63, 10.86]

Setup 與模型規模

總節點 3556，最大深度 10；joblib 324,329 bytes，Tensor ONNX 130,671 bytes。

Setup 步驟	中位數 ms	三次一次觀察的範圍 ms
訓練	141.425	141.225 至 143.487
載入 sklearn	17.502	12.465 至 25.458
Tensor 轉換	140.846	138.321 至 150.781
Tensor session 建立	2.583	2.020 至 2.618

Setup 各階段每個子實驗只觀察一次，且各階段排除部分保存 / 序列化工作；不能直接相加為完整 cold-start 或請求成本。

來源與口徑：[S11] summary.csv、runs.csv、model_sizes.csv、setup_times.csv；各子實驗 P25/P75 與更完整小數保留於其 summary / timings。

補充附錄 500 棵樹完整彙總

以下每列代表三個子實驗，每個子實驗 1,000 次正式 API 呼叫。Median、P95、throughput、speedup 均先在各次計算後再取中位數；方括號內為三次觀察範圍。ms 為每次批次呼叫時間。

Backend	批次	Median ms [範圍]	P95 ms	千筆/秒	加速 [範圍]
sklearn	1	20.98095 [20.95655, 21.03935]	30.07697	0.048	1.00 [1.00, 1.00]
ZipMap on	1	0.024 [0.01755, 0.0242]	0.0297	41.667	874.21 [865.97, 1198.82]
ZipMap off	1	0.02 [0.0188, 0.0201]	0.0251	50.000	1051.97 [1042.61, 1116.01]
sklearn	16	21.43275 [21.386, 21.4904]	30.15644	0.747	1.00 [1.00, 1.00]
ZipMap on	16	0.14535 [0.14425, 0.15205]	0.27521	110.079	147.85 [140.96, 148.26]
ZipMap off	16	0.1398 [0.1359, 0.1442]	0.22304	114.449	153.72 [148.63, 157.37]
sklearn	64	22.42995 [21.4604, 22.53855]	31.91671	2.853	1.00 [1.00, 1.00]
ZipMap on	64	0.9414 [0.9405, 0.94285]	1.20075	67.984	23.83 [22.76, 23.96]
ZipMap off	64	0.9168 [0.90645, 0.92115]	1.47132	69.808	24.35 [23.41, 24.86]
sklearn	256	24.53225 [24.1499, 24.8189]	34.18291	10.435	1.00 [1.00, 1.00]
ZipMap on	256	3.62945 [3.62925, 3.6433]	5.27197	70.534	6.76 [6.63, 6.84]
ZipMap off	256	3.522 [3.5124, 3.5644]	4.86334	72.686	6.96 [6.88, 6.97]

Setup 與模型規模

總節點 17754，最大深度 11；joblib 1,613,769 bytes，Tensor ONNX 669,804 bytes。

Setup 步驟	中位數 ms	三次一次觀察的範圍 ms
訓練	672.133	632.035 至 701.973
載入 sklearn	79.661	60.463 至 93.376
Tensor 轉換	610.695	601.594 至 640.671
Tensor session 建立	12.574	11.683 至 14.962

Setup 各階段每個子實驗只觀察一次，且各階段排除部分保存 / 序列化工作；不能直接相加為完整 cold-start 或請求成本。

來源與口徑：[S11] summary.csv、runs.csv、model_sizes.csv、setup_times.csv；各子實驗 P25/P75 與更完整小數保留於其 summary / timings。

來源清單與閱讀範圍

下列路徑以專案根目錄 scikit-learn_ONNX 為基準。新結果包簡稱 BUNDLE，即 new/COMP4330_Results_MC235E10_20261103_114239_UTC。實驗事實以保存的原始結果、設定及日誌為準，課程附件與 proposal 作背景來源。

來源	位置與內容
S01	RUN-001 output/experiment
S02	RUN-002 output/runs/20261030T154052Z_be01f368
S03	RUN-003 BUNDLE/output/runs/20261103T113724Z_5d3a5108
S04	RUN-004 BUNDLE/output/runs/20261103T113908Z_8f07f50f
S05	RUN-005 BUNDLE/output/runs/20261103T114026Z_2feb004b
S06	RUN-006 BUNDLE/output/runs/20261103T114144Z_9993ceea
S07	三份 ONNX_Experiment_Tracker.xlsx：專案根目錄、new 根目錄、BUNDLE。Results A20:M91；Correctness A8:M25；Run Log A7:W12、A33:Q38；Guide 全表。
S08	README.md；docs/ 全部 6 份 Markdown；onnx_benchmark/ 全部 12 個 Python 模組；pyproject.toml 與 5 個 requirements 檔。
S09	本地 logs/、BUNDLE/logs/ 全部日誌與 workflow；BUNDLE/MANIFEST.sha256；各 run provenance 與 verification。
S10	COMP4330SEF_P01_G02_GroupProjectProposal (1).pdf（4 頁）；上一層 COMP 4330SEF Project_2026.doc（課程要求）。
S11	output/tree_study_20261104 全部 348 檔；study_config、results_zh、頂層與九子實驗 CSV/JSON、模型、profiling、verification 與圖。新增及變更的核心程式亦已閱讀。

完整檔案覆蓋與去重

原始範圍為本地 output/experiment 24 檔、output/runs 24 檔、logs 8 檔、new 170 檔，共 226 個實體檔案（含副本）。新增研究另 348 檔，總計 574 個結果檔。另閱讀根目錄追蹤表、方法文件、舊 / 新核心程式、設定、proposal 與課程附件。

226 檔包括 114 JSON、8 JSONL、13 log、8 結果 Markdown、16 CSV、16 NPZ、16 ONNX、8 joblib、24 PNG、2 XLSX 及 1 manifest。文字完整讀取，JSON/JSONL 全量解析；二進位檔依類型檢查內容、結構或雜湊。重複圖像與模型依副本關係去重；18 張唯一結果圖已檢視。

新增研究含 23 CSV、203 JSON、10 Markdown、18 NPZ、18 ONNX、9 joblib、31 PNG、36 pstats。本地兩組舊結果與 BUNDLE 的相應副本一致，兩份 new 工作簿亦相同；副本、重新驗證或重複匯入未當成額外實驗。

閱讀範圍聚焦本任務的結果與直接方法來源；沒有把 .venv、.git、快取、其他既有產物或分發 ZIP 的重複內容列為新增實驗證據。沒有重新下載外部論文或上游程式來源，歷史 source_analysis 以既有分析紀錄處理。

本 PDF 所有新比較圖與統計皆由上述結果計算。新機比較採三次統計值的範圍或中位數，並於各圖說標明；沒有把它們誤作跨機器信賴區間。