RESULTS / 01

隨機森林與 ONNX：實測結果

10 / 100 / 500 棵樹 · 三次重複實驗 · CPU 單執行緒 · 實驗日期 2026-11-04（香港）

模型變大，不代表 ONNX 的加速比一定增加。本機實測顯示，小 batch 與大 batch 的趨勢不同；評估部署效益時，需要同時考慮樹數、batch 及輸出格式。

樹數	Batch 1 加速比	Batch 256 加速比	Tensor 延遲 ms（Batch 1 / 256）
10	54.50x	13.76x	0.0111 / 0.0469
100	346.37x	9.95x	0.0129 / 0.5016
500	1051.97x	6.96x	0.0200 / 3.5220

以上為 ONNX Tensor（關閉 ZipMap）相對 scikit-learn 的加速比，各次先算比值，再取三次中位數。這些是本機完整 probability API 的量測結果，並非純樹遍歷的加速比。

實驗設計與驗證

項目	固定設定 / 已完成的檢查
資料與模型	Breast Cancer Wisconsin；569 筆、30 特徵；分層 80/20、seed 42；455 訓練 / 114 原始測試案例。
比較矩陣	3 種樹數 × 4 種 batch（1、16、64、256）× 3 種執行方式 × 3 次重跑；共 108 組計時配置。
計時方法	每配置 50 次暖機，10 輪 × 100 次正式計時；依輪次輪換 runtime 順序，依重跑輪換樹數順序。
完成狀態	9 個子實驗、108,000 筆正式計時；38 項測試、22 個 source files 的 mypy 與獨立結果驗證均通過。

所有正式計時完成後才收集 profiling。資料來源：output/tree_study_20261104；完整原始計時、模型與 trace 均保留。

RESULTS / 02

完整比較：延遲、P95 與加速比

每格延遲格式為「median / P95」，單位 ms；均先按每次實驗計算，再取跨次中位數。

樹數	Batch	sklearn median / P95	ZipMap median / P95	Tensor median / P95	ZipMap 加速比	Tensor 加速比	Tensor 加速比 三次觀察範圍
10	1	0.605 / 0.9398	0.013 / 0.0152	0.0111 / 0.0133	46.54x	54.50x	42.90 - 70.00x
10	16	0.6142 / 0.9949	0.0189 / 0.0282	0.0139 / 0.021	33.98x	46.21x	40.41 - 54.54x
10	64	0.609 / 0.9049	0.042 / 0.05342	0.0225 / 0.02835	14.50x	27.07x	23.89 - 37.65x
10	256	0.6613 / 1.03	0.1274 / 0.1593	0.0469 / 0.07679	5.12x	13.76x	12.00 - 17.97x
100	1	4.468 / 7.556	0.0148 / 0.0199	0.0129 / 0.0207	301.40x	346.37x	345.79 - 457.58x
100	16	4.505 / 6.78	0.0406 / 0.0489	0.0349 / 0.04875	109.22x	131.74x	127.99 - 135.51x
100	64	4.709 / 6.576	0.1327 / 0.2639	0.0851 / 0.1635	35.73x	55.09x	41.79 - 59.05x
100	256	5.06 / 7.579	0.5931 / 1.037	0.5016 / 0.6545	8.45x	9.95x	9.63 - 10.86x
500	1	20.98 / 30.08	0.024 / 0.0297	0.02 / 0.0251	874.21x	1051.97x	1042.61 - 1116.01x
500	16	21.43 / 30.16	0.1454 / 0.2752	0.1398 / 0.223	147.85x	153.72x	148.63 - 157.37x
500	64	22.43 / 31.92	0.9414 / 1.201	0.9168 / 1.471	23.83x	24.35x	23.41 - 24.86x
500	256	24.53 / 34.18	3.629 / 5.272	3.522 / 4.863	6.76x	6.96x	6.88 - 6.97x

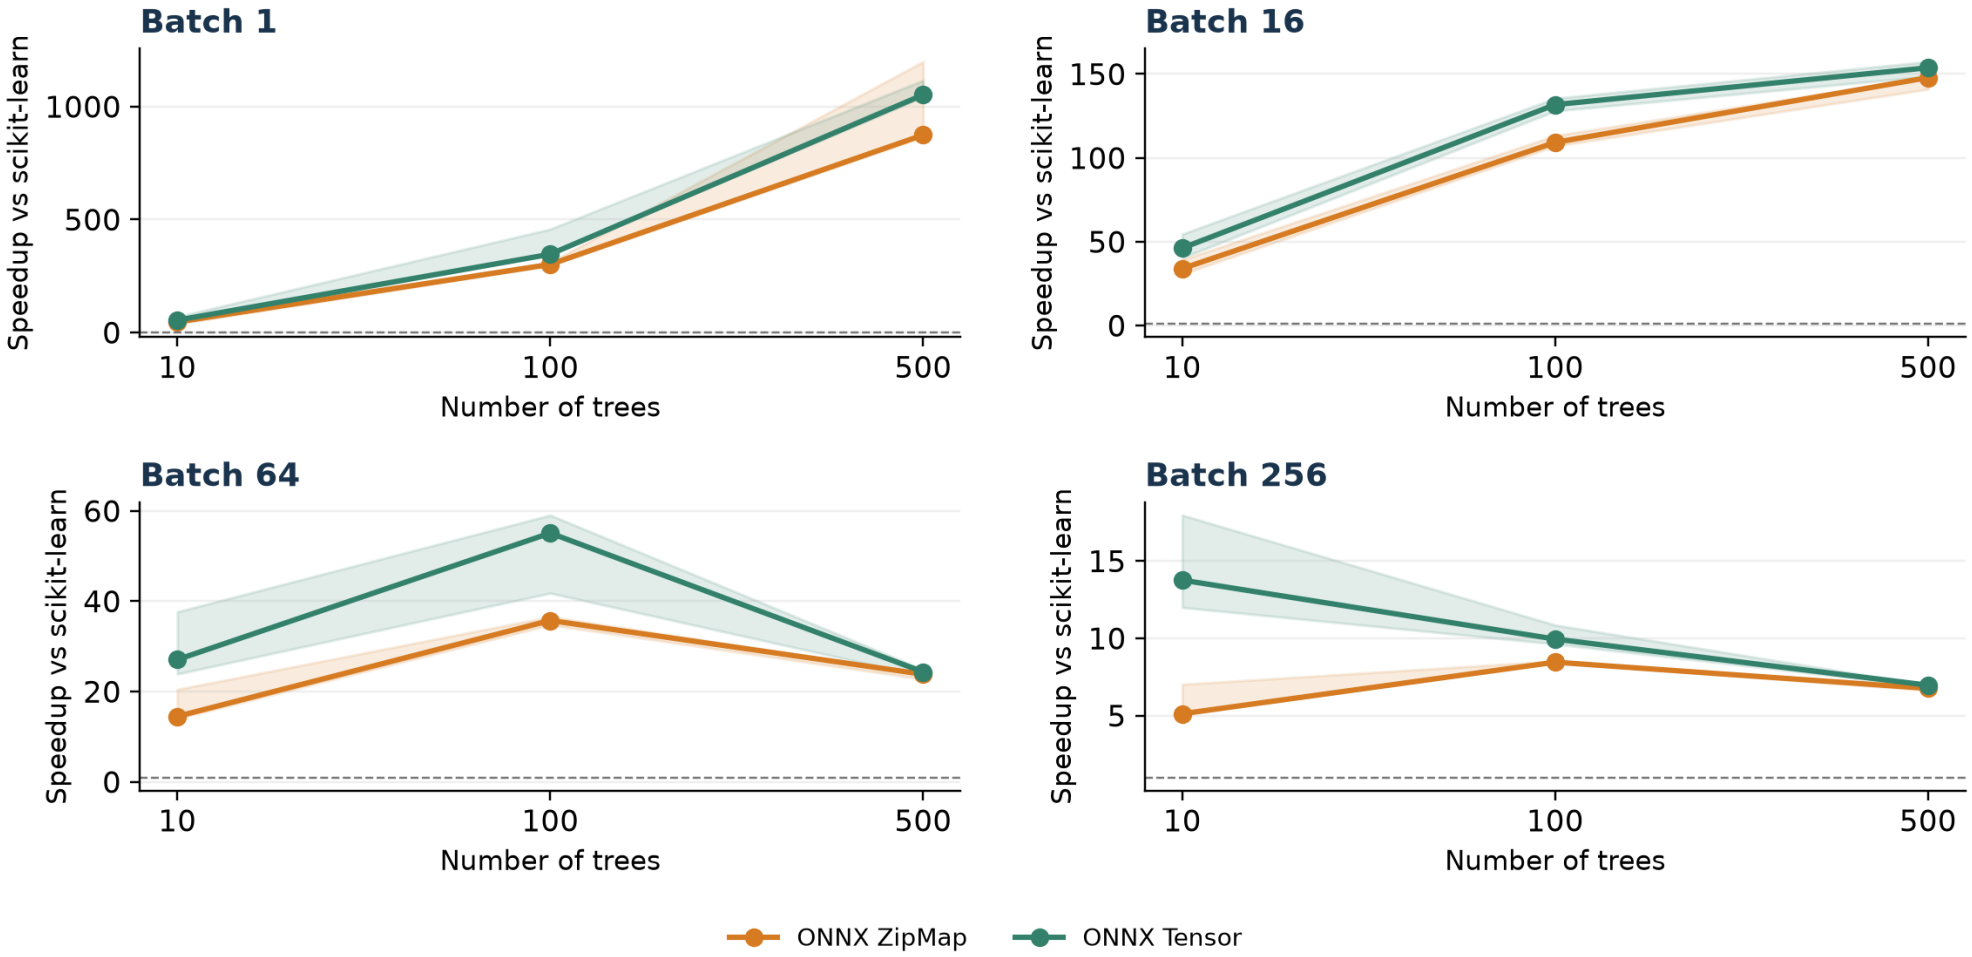
範圍為三次加速比的最小值與最大值，不是信賴區間。由於每項指標各自取中位數，表內兩個延遲中位數相除，未必正好等於加速比中位數。

ZipMap 開啟時返回 sequence of maps；關閉時返回機率 tensor。此處比較的是整個 API 路徑，包含返回物件建立；不包含字典轉矩陣的後續正規化。P25/P75、吞吐量及各次數值見 summary.csv 與 runs.csv。

RESULTS / 03

加速比：樹數的影響取決於 batch

折線為三次加速比的中位數；色帶為最小值至最大值。各小圖使用各自的縱軸刻度。

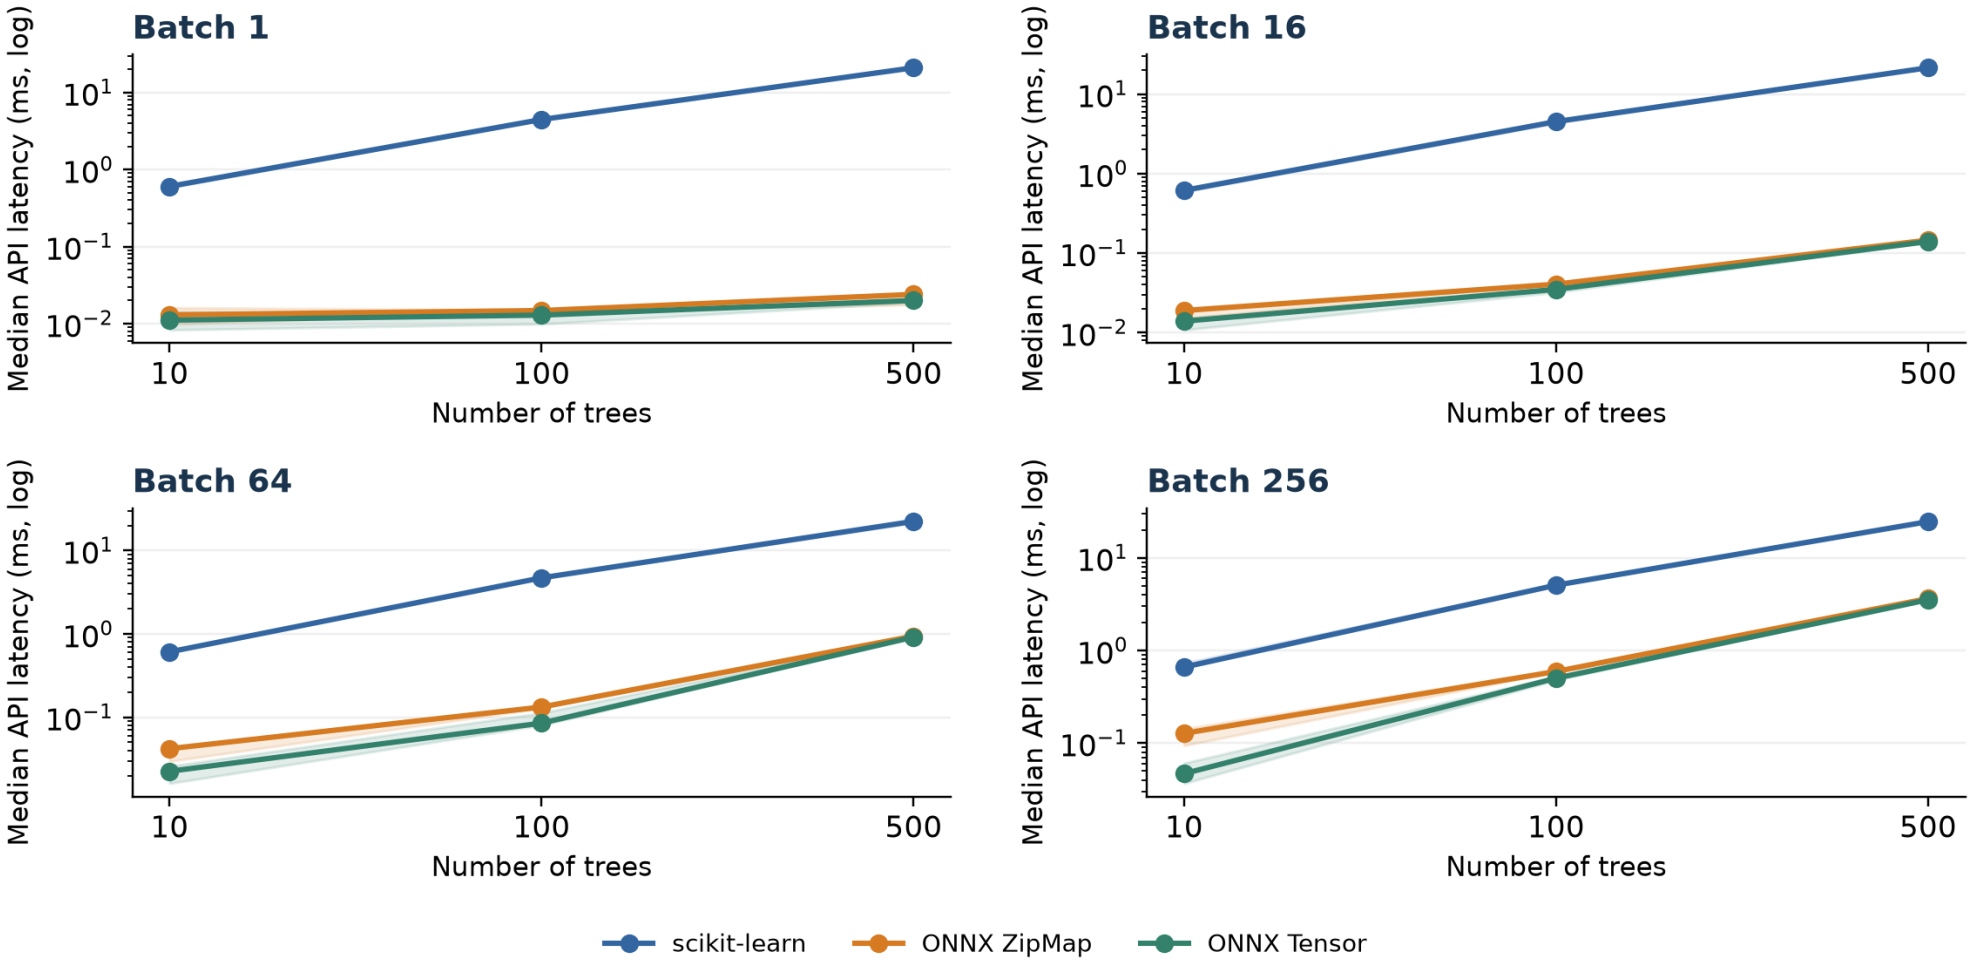


Tensor 的 batch 1 加速比隨樹數上升，batch 256 則下降；batch 64 先上升再下降。全部 12 種樹數 × batch 的彙總結果中，ONNX 都較 sklearn 快，但此結果不能外推到其他資料集或機器。

RESULTS / 04

絕對延遲：加速比背後的時間差

縱軸為每次 probability API 呼叫的毫秒數，採對數刻度；色帶為三次中位數的觀察範圍。



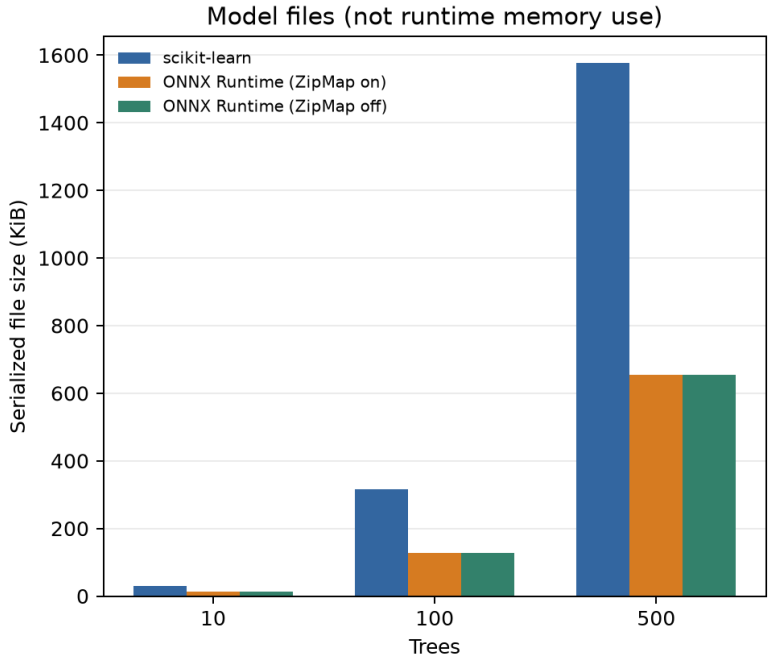
500 棵樹、batch 1：sklearn 約 20.981 ms，ONNX Tensor 約 0.020 ms。batch 256：兩者約 24.532 ms 與 3.522 ms。相對收益下降不等於 ONNX 變慢於 sklearn；要同時讀取延遲與加速比。

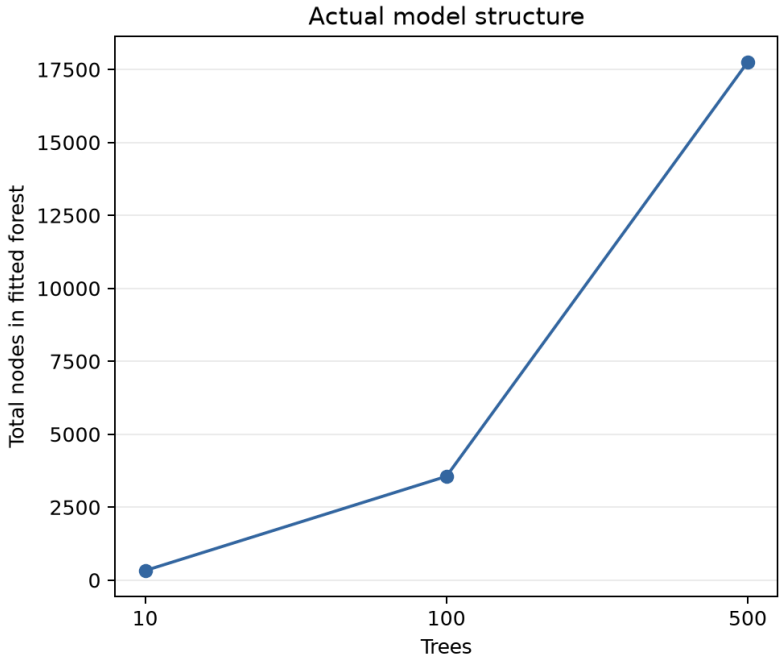
RESULTS / 05

模型大小與結構

三次重跑的模型大小與結構一致；KiB = 1,024 bytes。檔案大小不代表 runtime 記憶體占用量。

樹數	總節點數	最大深度	sklearn KiB	ZipMap KiB	Tensor KiB
10	326	10	30.63	12.40	12.25
100	3,556	10	316.73	127.75	127.61
500	17,754	11	1,575.95	654.25	654.11



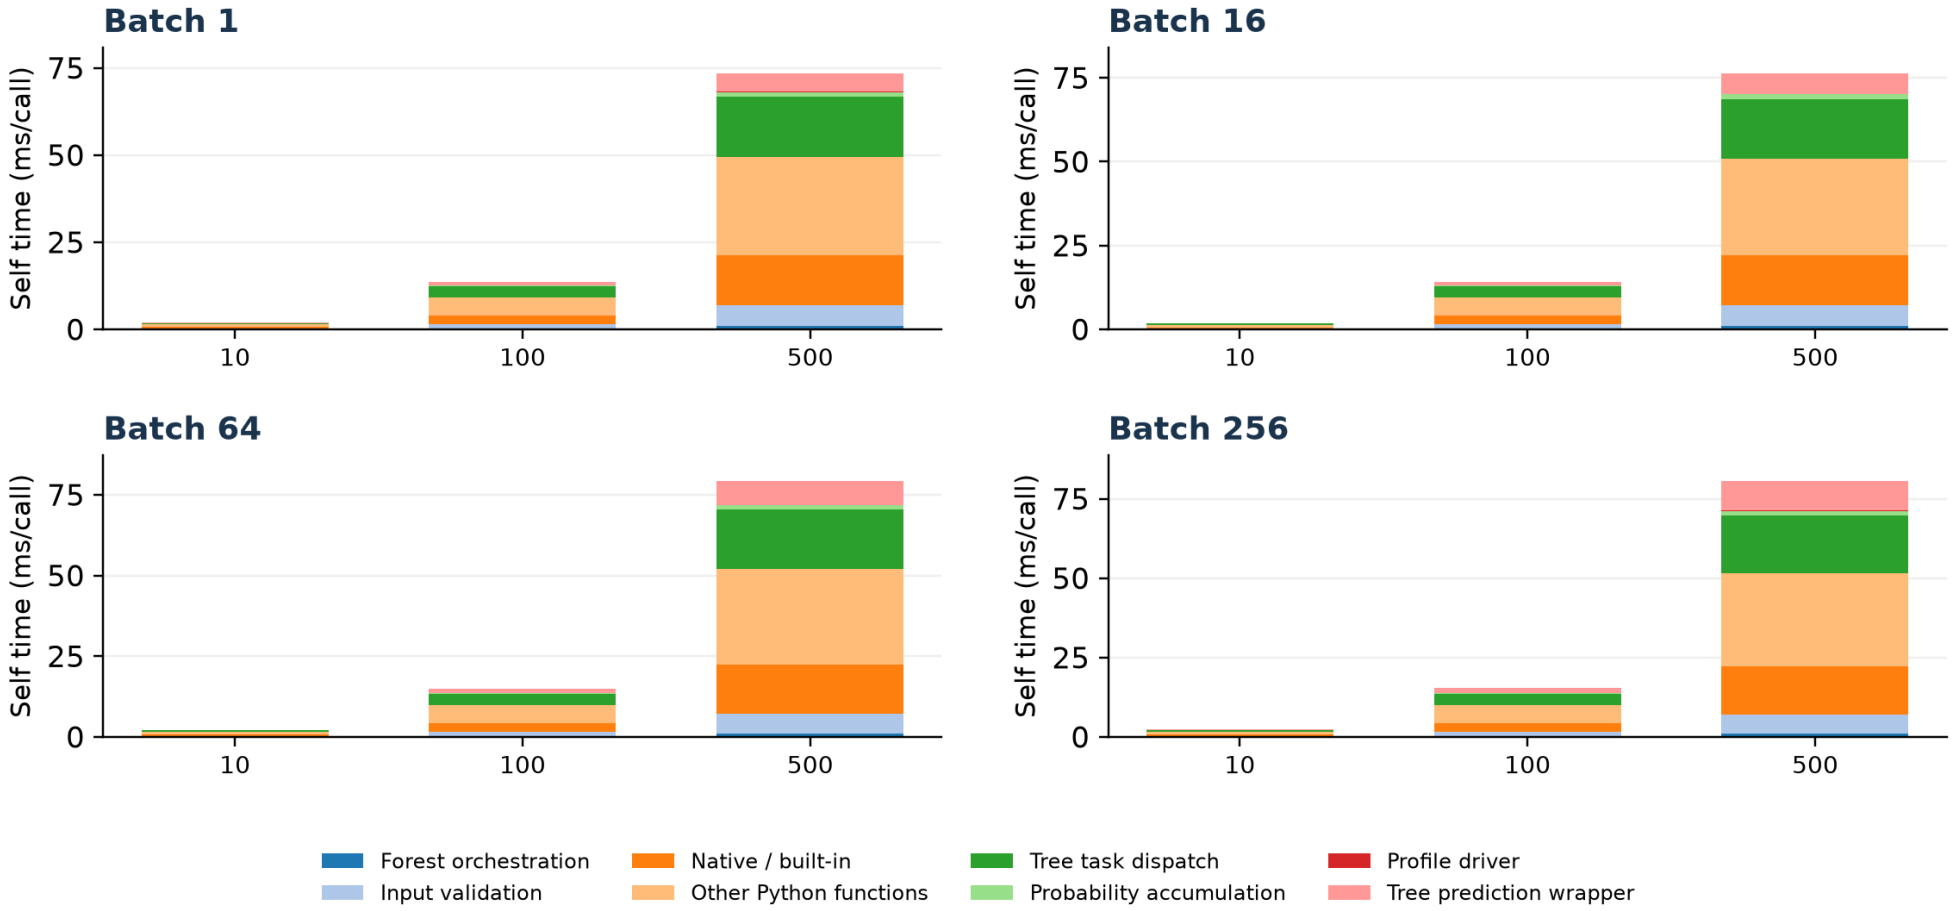


ONNX 檔案較小，是序列化形式的觀察；本研究同時改變了樹數與森林結構，沒有單獨控制檔案大小，也沒有量測快取命中率、SIMD 或編譯器最佳化。因此不能把『檔案較小』直接當作已證明的加速原因。

RESULTS / 06

Profiling：sklearn 的 Python 呼叫路徑

每個子實驗與 batch 各剖析 100 次推理；下圖將 exclusive self time 按函式來源分類，再取三次中位數。



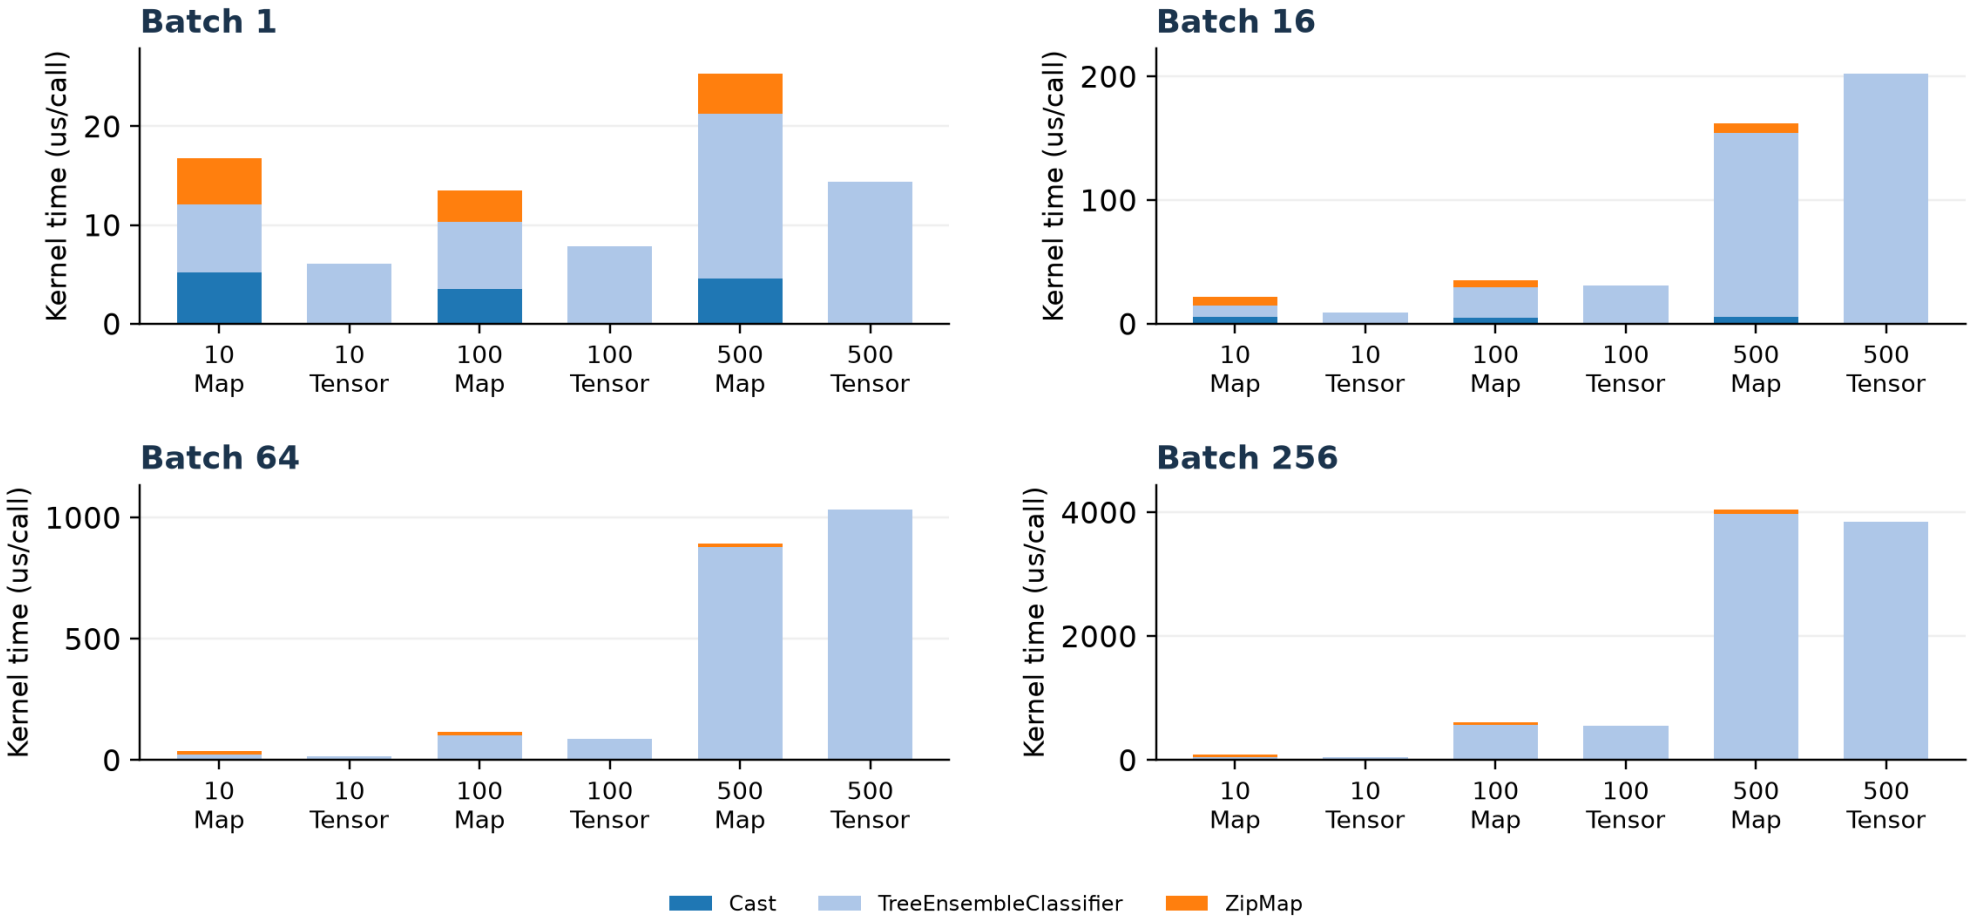
500 棵樹、batch 1 的每次 100-call profile，出現 50,000 次逐樹調度 wrapper 呼叫及 50,000 次 DecisionTreeClassifier.predict_proba。warnings filter 的反覆設定也可見於 trace；這代表警告處理設定操作，不代表真的產生大量警告。

cProfile 看不到 Cython 樹遍歷的內部步驟，部分 native 工作會記在 Python caller。分類中的「other」保留未單獨分類的函式。Profiler 有明顯額外負擔，圖中時間與占比不能當作正式 benchmark 的精確耗時分解。

RESULTS / 07

Profiling：ORT 原生算子

依 model_run 時間窗排除 50 次暖機；統計實際 kernel events。Map = ZipMap 開啟，Tensor = ZipMap 關閉。



Tensor 圖的主要算子為 TreeEnsembleClassifier；ZipMap 圖另觀察到 ZipMap 及 Cast。即使只要求機率輸出，這次 trace 仍顯示 Cast 執行。算子時間不完整涵蓋 Python binding、feed 處理與返回容器建立。

ORT profiling 與上一頁 cProfile 是不同觀察邊界，均有 instrumentation overhead。不能用正式 API latency 減去這裡的算子時間，宣稱差值就是精確 wrapper 成本；ZipMap/Tensor 的整體差異也不能全部歸因於 ZipMap 單一算子。

RESULTS / 08

如何解釋加速，以及結果的適用範圍

同一森林的 runtime 比較通過一致性檢查；不同樹數是不同模型，準確率可以不同。

可支持的機制解釋：sklearn 的樹遍歷本身已是編譯程式，但森林 API 仍須經 Python 層驗證、逐樹調度、機率累加與平均；ONNX 將整個森林編碼為 TreeEnsembleClassifier，由原生 ensemble kernel 執行。剖析與這種路徑差異相符，但不能據此精確分配每一項正式加速收益。

一次性準備成本（ms；三次觀察的中位數）

步驟	10 棵樹	100 棵樹	500 棵樹
森林訓練	10.823	141.425	672.133
sklearn 模型載入	8.018	17.502	79.661
ONNX 轉換 / ZipMap	36.933	163.038	648.787
ONNX 轉換 / Tensor	12.669	140.846	610.695
ORT session / ZipMap	1.382	3.097	15.291
ORT session / Tensor	0.740	2.583	12.574

每個子實驗各量一次；訓練不含儲存，轉換不含 checker 與序列化。不可相加當作完整冷啟動時間，也不計入穩態加速比。

樹數	原始測試集準確率	ONNX / sklearn 標籤一致率	最大機率絕對誤差
10	107/114 (93.86%)	100%	1.19209e-07
100	109/114 (95.61%)	100%	6.55651e-07
500	109/114 (95.61%)	100%	5.78165e-06

誤差均低於 1e-5。僅 114 個未重複案例用於準確率；batch 256 的重複輸入是人工效能負載。單一資料集、單一 CPU、固定 seed；三次重跑不代表不同資料集或種子，電源模式與背景負載未由程式控制。

環境：AMD Ryzen AI 7 H 350；Windows 11；Python 3.12.10；scikit-learn 1.9.1；ORT 1.31.0；CPUExecutionProvider、sequential、intra/inter-op threads = 1。來源：study_config.json、summary.csv、model_sizes.csv、setup_times.csv、profiling_summary.csv、各子實驗 correctness.json，以及 verification/。